

STA323 Assignment1

12312515 王洛源

Q1

(1) 代码文件见Q1.py相应部分（已用注释标明），运行结果如下：

```
ent1/Q1_1.py
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
26/03/14 11:14:34 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
+-----+-----+-----+-----+-----+-----+
|InvoiceNo|StockCode|Description|Quantity|InvoiceDate|UnitPrice|CustomerID|Country|
+-----+-----+-----+-----+-----+-----+
| 536365| 85123A|WHITE HANGING HEA...| 6|12/1/2010 8:26| 2.55| 17850|United Kingdom|
| 536365| 71053| WHITE METAL LANTERN| 6|12/1/2010 8:26| 3.39| 17850|United Kingdom|
| 536365| 84406B|CREAM CUPID HEART...| 8|12/1/2010 8:26| 2.75| 17850|United Kingdom|
| 536365| 84029G|KNITTED UNION FLA...| 6|12/1/2010 8:26| 3.39| 17850|United Kingdom|
| 536365| 84029E|RED WOOLLY HOTTIE...| 6|12/1/2010 8:26| 3.39| 17850|United Kingdom|
+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
成功：已终止 PID 32472 (属于 PID 34276 子进程)的进程。
成功：已终止 PID 34276 (属于 PID 24144 子进程)的进程。
成功：已终止 PID 24144 (属于 PID 20500 子进程)的进程。
```

(2) 使用git bash读取原始csv文件并找到出现频率最高的5个stockcode的指令和截图如下：

```
$ tail -n +2 Q1_data.csv \
| cut -d',' -f2 \
| sort \
| uniq -c \
| sort -nr \
| head -5 \
| awk '{print $2 "," $1}'
85123A,2313
22423,2203
85099B,2159
47566,1727
20725,1639
```

(3) 代码文件见Q1.py相应部分（已用注释标明），结果可视化图片见q1_obs1_country_revenue.png和q1_obs2_hourly_orders.png

在obs1中，我们可以看到英国（United Kingdom）的总销售额明显高于其他国家，这可能是因为数据统计范围的限制，说明本数据集相关的市场主体为英国，明确了主要目标客户；而在obs2中，可以看到白天尤其是中午（11-15时）的销售额最高，这也符合人们的作息规律，可能有助于广告投放或其他营销策略的制定

Q2

根据题目要求，我们首先对给出的数据按照要求进行处理，最终合并成一个清洗好的数据文件 Q2_final.csv，所用代码文件为q2_prepare.py

(1) 代码文件为Q2_1.py，运行结果如下，统计结果文件保存为Q2_1_result.csv

ent1/Q2_1.py	v_call	j_call	occurrence_count	longest_sequence	longest_sequence_length
238	IGKV3-20*01	IGKJ1*01	4504	CTCTTCCTCCTGCTACTCTGGCTCCCAGTCTCAGATACCACCGGGG...	422
239	IGKV3-20*01	IGKJ2*01	4431	CTCTTCCTCCTGCTACTCTGGCTCCCAGATACCACCGGAGAAATGG...	489
78	IGKV1-5*03	IGKJ1*01	3598	ATGAGGGTCCCTGCTCAGCTGCTGGGGCTCCTGCTGCTCTGGCTCC...	413
67	IGKV1-39*01	IGKJ2*01	3234	ATGAGGGTCCCTGCTCAGCTGCTGGGGCTCCTGCTACTTTGGCTCC...	426
230	IGKV3-15*01	IGKJ2*01	3035	CTCTTCCTCCTGCTACTCTGGCTCCCAGATACCAGTGGAGAAATAG...	429

(3) 所用shell脚本为q2_3.sh，由于清洗规则比较复杂，我使用python代码进行并行处理，相关代码为process_chunk.py，运行结果如下，输出文件为SRR12326775_1_Light_Bulk_final.csv

```
$ bash q2_3.sh
Step 1: extract header (line 2)
Step 2: extract data rows (from line 3 onward)
Step 3: split data into 8 chunks
Step 4: add header to each chunk
Step 5: process each chunk in parallel
Processed q2_3_work/chunks/chunk_01.csv -> q2_3_work/clean_chunks/chunk_01_clean.csv, rows=10727
Processed q2_3_work/chunks/chunk_00.csv -> q2_3_work/clean_chunks/chunk_00_clean.csv, rows=10744
Processed q2_3_work/chunks/chunk_06.csv -> q2_3_work/clean_chunks/chunk_06_clean.csv, rows=10718
Processed q2_3_work/chunks/chunk_05.csv -> q2_3_work/clean_chunks/chunk_05_clean.csv, rows=10683
Processed q2_3_work/chunks/chunk_02.csv -> q2_3_work/clean_chunks/chunk_02_clean.csv, rows=10714
Processed q2_3_work/chunks/chunk_07.csv -> q2_3_work/clean_chunks/chunk_07_clean.csv, rows=10700
Processed q2_3_work/chunks/chunk_04.csv -> q2_3_work/clean_chunks/chunk_04_clean.csv, rows=10678
Processed q2_3_work/chunks/chunk_03.csv -> q2_3_work/clean_chunks/chunk_03_clean.csv, rows=10686
Step 6: merge all cleaned chunk outputs
Done. Final output saved to SRR12326775_1_Light_Bulk_final.csv
```

(4) 代码文件为Q2_4.py，运行结果如下：

v_call	j_call	pair_count	avg_cdr3_aa_length
IGKV3-20*01	IGKJ1*01	4504	9.018872
IGKV1-39*01	IGKJ2*01	3234	9.156463
IGKV3-15*01	IGKJ2*01	3035	9.786820

Q3

(1)

对于这个问题我使用了三种不同的prompt。

第一版prompt基本上就是复制了题干，内容如下：

我是一家初创公司的CTO，计划设计一款国际化的基于AI能力的类似大众点评的APP，请你帮我设计这个产品的系统架构，并解释各部分作用

LLM给出的回答如下：

你好！作为初创公司的CTO，你选择了一个极具挑战性但也充满机遇的赛道。要设计一款**国际化、AI原生**的“大众点评”类应用，我们不能简单照搬传统架构，而必须采用“**AI Native**”的设计思路——即AI不仅仅是功能，更是系统的核心驱动力。

基于最新的AI技术趋势（如大模型、RAG、向量数据库）以及国际化需求，我为你设计了以下系统架构。这套架构分为六大核心层级，旨在解决多语言适配、海量非结构化数据处理以及个性化推荐等关键问题。

 核心系统架构概览


我们将系统划分为：**用户交互层、AI网关与编排层、智能应用层、数据与知识库层、基础设施层。**

表格			
模块名称	核心技术/组件	主要作用与价值	
多模态情感分析	BERT/Qwen, CNN, NLP	深度理解评价。不仅判断好评/差评，还能分析出具体的“口味”、“服务”、“环境”得分，甚至识别图片中的菜品质量。	
RAG 检索增强	向量数据库, Embedding	解决幻觉与时效性。当用户问“这家店最近评价怎么样”时，系统先检索最新评论库，再让AI总结，确保答案准确不瞎编。	
智能推荐引擎	协同过滤, 混合推荐算法	千人千面。结合用户历史行为（点击/收藏）和AI分析出的口味偏好（如“喜辣”、“素食”），提供精准的商家列表。	
跨语言交互	大模型翻译, i18n框架	打破语言障碍。让不懂日语的游客能看懂日本的居酒屋评论，让外国商家能回复中文用户的提问。	
数据隐私与安全	差分隐私, GDPR合规组件	合规护盾。针对国际化业务，确保用户数据符合欧盟GDPR、美国CCPA等法规，敏感数据脱敏处理。	

第二版prompt，我将重点放在了“国际化”上，内容如下：

我是一家初创公司的CTO，我们公司计划推出一款对标大众点评，但更加国际化，面向全球的生活助手软件。现在请你帮我设计这个产品的系统架构，尤其要注明哪些架构是专门为了国际化（如符合不同国家的法律法规，翻译问题等）而特殊设计的，并解释各部分作用

然后LLM给出了这样的架构图：



第三版prompt，我将重点放在了对大众点评主要功能的拆解上，内容如下：

我是一家初创公司的CTO，计划设计一款国际化的基于AI能力的类似大众点评的APP，具备包括但不限于餐厅，娱乐场所，酒店，电影院等消费场所的搜索，评价，团购优惠等服务，现在请你帮我设计这个产品的系统架构，并解释各部分作用

LLM提供了一个五个核心层次组成的系统架构，包括数据采集层，数据处理与存储层，AI核心引擎层，业务应用层和用户交互层。整体结果和第一版prompt差不多。

根据以上三轮对话，我发现LLM本身在不借助提示的情况下，对题干要求中的大众点评功能和基于AI能力的理解比较到位，但对于全球化这一关键点考虑不够周到。例如，第一、三版prompt中，LLM都只部分考虑了翻译系统和数据隐私的实现方式，但第二版的LLM考虑了用户的定位，归属地判断，多币种支付，甚至包括高德地图/谷歌地图的展示也考虑了进去。不过第二版的LLM相当于只针对国际化这一问题提出了解决方案，将其整合到第一版的架构中，应当就是一套比较完善的体系了。

(2)

PostgreSQL：关系型数据库，强调可靠性、数据完整性、SQL能力和可扩展性；以ACID、一致性、可扩展能力和扩展生态见长；还支持json/jsonb、全文检索、地理扩展PostGIS；成熟、开源、生态强。

MongoDB: 官方提供内建的 geospatial search、全文搜索、vector search; 支持 ACID 事务; 支持分片, 适合大规模水平扩展; 更偏文档模型与灵活对象存储; 虽然功能很多, 但对于强关系、强事务、复杂 SQL 型主业务不够稳定。

Snowflake: 架构强调存储与计算分离, 擅长分析型查询、弹性计算、数据共享和统一分析; 官方也支持 hybrid tables / Unistore, 在向事务场景扩展; 产品收费, 定位更偏分析而非经典应用主库, 更适合分析平台/数仓。

从DB-Engines排名来看, 三者都属于主流数据库。而对于题干给出的特定问题, 在线主业务必须先保证数据一致性、事务可靠性、复杂关系查询能力、成熟索引与 SQL 能力以及后期扩展能力。总体来看PostgreSQL更适合作为本产品的主业务数据库。

我在第 (1) 问第一版prompt的对话中使用下面的prompt询问LLM对于数据库选择的建议, LLM做出了和我相同的选择。

根据我们的产品特点, 分析PostgreSQL , MongoDB , Snowflake这三个数据库对于我们产品适配的优缺点, 并选出哪个更适合做我们的主业务数据库

四、最终建议: PostgreSQL 作为主业务数据库

我的明确建议是: 选用 PostgreSQL 作为您的主业务数据库。

为什么是 PostgreSQL?

1. **一库满足80%需求**: 您的核心业务——用户账号、商户信息、评价内容、预订订单、支付记录——都需要严格的事务一致性, 这是PostgreSQL的强项 ① ④
2. **多模数据能力**: 点评类应用的核心是“评价”, 每条评价包含结构化评分+非结构化文本+图片。PostgreSQL的JSONB字段可以完美存储评价的扩展属性, 同时保持关系模型的优势 ④
3. **地理位置能力**: “附近的人气餐厅”是您产品的核心功能。PostgreSQL + PostGIS 是目前开源领域最强大的地理空间方案 ④
4. **AI就绪**: 未来您会需要语义搜索、智能推荐、个性化推送。PostgreSQL的 pgvector 扩展可以直接存储向量 embeddings, 无需引入专用向量数据库 ⑤ ⑧
5. **成本可控**: 初创公司预算有限, PostgreSQL开源免费, 云服务商提供的托管版 (如AWS RDS、阿里云RDS) 也价格合理
6. **开发者熟悉度**: 2026年PostgreSQL已成为开发者最常用的数据库, 招聘、学习、社区支持都有保障 ①