

电信客户生存分析报告

一、任务背景

业务问题

某电信公司面临客户流失问题，尤其是**月付用户**流失率较高。公司希望：

- 预测客户流失风险
- 识别影响客户留存的关键因素
- 量化不同客户群体的生命周期价值 (CLV)
- 制定针对性的客户保留策略

为什么用生存分析？

传统分类模型只能预测“是否流失”，但无法回答：

- 客户能留存多久？** → 生存时间预测
- 某因素如何影响流失速度？** → 风险比分析
- 客户在整个生命周期内值多少钱？** → CLV 计算

生存分析同时考虑**时间**和**事件**，更适合客户流失场景。

数据集

- 来源:** IBM Telco Customer Churn Dataset
- 规模:** 7,043 条客户记录, 21 个特征
- 筛选:** 仅保留月付用户 + 有互联网服务的用户 (3,351 条)
- 流失率:** 约 50%

二、主要步骤

步骤 1: 数据加载与预处理

原始数据 → 列名标准化 → 转换 churn 为数值 → 筛选样本 → 删除缺失列

关键操作:

- `churn` : 'Yes' → 1, 'No' → 0
- 筛选: `contract == 'Month-to-month'` 且 `internetservice != 'No'`
- 删除 `totalcharges` (有缺失值)

步骤 2: Kaplan-Meier 生存曲线

目的: 描述整体客户的生存模式

核心变量:

- `T` (tenure) : 生存时间 (在网月数)
- `C` (churn) : 事件指示 (1=流失, 0=删失)

输出: 中位生存时间 (50% 客户流失的时间点)

步骤 3: Log-rank 检验

目的: 检验不同组别之间的生存曲线是否有显著差异

判断标准:

- $p < 0.05$: 组间差异显著 *
- $p \geq 0.05$: 组间差异不显著

检验特征: `onlinesecurity`, `gender`, `internetservice`

步骤 4: Cox 比例风险模型

目的: 量化各因素对流失风险的影响

输出:

- **风险比 (Hazard Ratio):**
 - $HR > 1$: 增加流失风险
 - $HR < 1$: 降低流失风险 (保护因素)
- **Concordance Index:** 模型预测准确性

特征: `dependents`, `internetservice`, `onlinebackup`, `techsupport`, `paperlessbilling`

步骤 5: AFT 模型 (加速失效时间)

目的: 提供另一种建模视角, 与 Cox 模型互补

模型选择指标: AIC (越小越好)

步骤 6: 客户生命周期价值 (CLV) 计算

公式:

$$CLV = \sum [生存概率 \times 月利润 / (1+折现率)^{月数}]$$

参数:

- 月利润: 30 元
- 年折现率: 10%
- 预测期: 36 个月

风险分层:

- 低风险:** 有家属 + DSL + 在线备份 + 技术支持
- 高风险:** 无上述保护因素

三、结果展示

3.1 描述性统计

指标	数值
样本量	3,351 条
流失率	~50%
中位生存时间	34 个月

解读: 月付用户中, 约一半在 34 个月内流失。

3.2 Log-rank 检验结果

特征	p 值	显著性
onlinesecurity	< 0.05	* 显著
gender	> 0.05	不显著
internetservice	< 0.05	* 显著

解读:

- 有/无在线安保的客户流失率显著不同
- 性别对流失率影响不大
- DSL 和 Fiber 用户的流失率显著不同

3.3 Cox 模型结果

指标	数值
Concordance Index	0.641

解读: 模型预测准确性约 64%，有一定预测能力 (>0.6 可用)。

关键发现 (风险比)：

- techsupport_Yes : HR < 1 → 技术支持是**保护因素**
- paperlessbilling_Yes : HR > 1 → 无纸账单**增加流失风险**
- dependents_Yes : HR < 1 → 有家属**降低流失风险**

3.4 AFT 模型结果

指标	数值
AIC	13,698.7

解读: 用于模型比较，数值越小拟合越好。

3.5 客户生命周期价值 (CLV)

客户类型	36 月 CLV
低风险客户	843.8 元
高风险客户	485.3 元
差距	358.5 元

解读: 通过推广附加服务，单客户可多创造约 359 元价值。

四、结果解释与建议

4.1 核心发现

1. 中位生存时间 34 个月

- 月付用户平均在 3 年内流失一半
- 需在前 12 个月重点干预

2. 保护因素（降低流失风险）

-  有家属 (dependents_Yes)
-  技术支持 (techsupport_Yes)
-  在线备份 (onlinebackup_Yes)
-  DSL 网络（相比 Fiber）

3. 风险因素（增加流失风险）

-  无纸账单 (paperlessbilling_Yes)
-  Fiber 网络（相比 DSL）
-  银行转账/信用卡自动支付

4. CLV 差距显著

- 低风险客户价值是高风险的 1.7 倍
- 附加服务有明显 retention 效果

4.2 业务建议

短期行动（0-3 个月）

1. 推广技术支持服务

- 目标：新入网用户 100% 覆盖
- 预期：降低流失率 10-15%

2. 优化 Fiber 用户 onboarding

- 问题：Fiber 用户流失率高于 DSL
- 行动：首月主动回访 + 使用指导

3. 无纸账单用户关怀

- 问题：无纸账单用户流失风险高
- 行动：发送纸质账单样本 + 优惠激励

中期策略 (3-12 个月)

1. 家庭套餐捆绑

- 依据：有家属用户留存率显著更高
- 策略：推出家庭共享流量/宽带套餐

2. 附加服务打包

- 依据：在线备份 + 技术支持用户 CLV 更高
- 策略：月付 +10 元得双服务

3. 早期预警系统

- 依据：中位生存时间 34 个月
- 策略：入网 6/12/24 个月时触发关怀

长期优化 (12+ 个月)

1. 动态定价模型

- 基于 Cox 模型风险评分
- 高风险用户提供折扣/升级

2. CLV 驱动的资源分配

- 高 CLV 客户：专属客服 + 优先支持
- 低 CLV 客户：自动化服务 + 自助渠道

4.3 模型局限性

- 数据时效性:** 数据为历史快照，市场变化可能影响模型效果
- 未考虑外部因素:** 竞争对手定价、经济周期等
- 样本偏差:** 仅分析月付用户，结论不适用于长期合同用户

4.4 后续改进方向

- 加入时间变量:** 用户入网年份、季节因素
- 交互效应:** 检验特征之间的交互作用
- 动态预测:** 基于用户行为实时更新风险评分
- A/B 测试:** 验证干预措施的实际效果

附录：输出文件

文件	说明
survival_analysis.ipynb	完整分析代码（带注释）
survival_analysis.png	生存曲线 + CLV 对比图
survival_curve.png	Kaplan-Meier 生存曲线
results.csv	关键指标汇总