

Project2 Report

12312515 王洛源

Q1

(1)

我阅读了相关材料，总结提炼了三条可能有效的数据选择方法如下：

1. **质量筛选** 综述中提到很多 instruction 选择方法已经转向自动质量评分、错误回答过滤、强模型打分，在本项目中，所需数据库 DataMind-12K 本身是 agent trajectory 数据，真正影响 SFT 效果的，最重要的是样本是否正确、完整、可执行。对数据科学和数学建模任务，例如本项目要完成的生成式数据代理系统的训练而言，来自数据的错误步骤、错代码、空泛解释会直接污染模型。这一选择方法可以通过先正则，再调用模型二次筛选来完成。
2. **复杂度/难度筛选** 对于生成式数据代理系统而言，体系的核心是多步推理、分析流程和代码执行链。因此训练数据需要有一定的难度和复杂度。如果只保留非常简单的问答，模型会学不到 agent 的关键能力。综述材料也明确把 difficulty / complexity 视为 instruction 数据选择的重要方向。这一选择方法可以通过优先保留多步骤任务，或带公式推导、统计分析等的数
据，降低一问一答的简单样本比例来实现。
3. **多样性选择** 阅读材料提到对于类似本项目的任务而言，训练数据需要更宽的任务覆盖和形式覆盖，模型才更能泛化到真实用户问题。这一选择方法可以通过按任务类别或者输出形式分层采样实现。

(2)

我在课程服务器上上传了数据，配置好了后面要用的千问模型。然后抽取了部分数据进行观测，设置了（1）问中方法1和2的正则条件，然后进行多样性选择，结果如下：

```

[1] Loading data from ./data/datamind_12k.json
Raw samples: 11707
[2] Loading tokenizer from ./model
[3] Filtering summary
    parse_fail: 0
    low_score_drop: 302
    duplicate_drop: 0
    too_long_drop: 921
    remaining: 10484
[4] Bucket distribution
    sql_database: 4591
    statistics: 3204
    csv_excel_analysis: 2196
    machine_learning: 276
    math_modeling: 217
[5] Done

```

可以看到数据集的质量较高，质量分和复杂度分都比较高，因此正则方法并没有过滤太多数据。另外这里也可以调用模型来进一步筛选数据，但在本项目中，我担心后面要用的0.8B模型能力不足，因此没有调用。

(3)

由于服务器仅提供 CPU 资源，我采用了基于 LoRA 的参数高效微调。以下是我的程序运行结果和生成的ckpt：

```

=====
[Main] trainer.fit() finished.
=====
[Main] Ray Train finished
Result(metrics=None, checkpoint=None, error=None, path='/data/project2/qwen_lora_ra
fs.LocalFileSystem object at 0x78abc8752ef0>)
=====

```

📁 / project2 / qwen_lora_ray_output /

Name	Modified
📁 best_lora	1h ago
📁 checkpoint_step_50	57m ago
📁 final_lora	48m ago
📁 qwen_lora_sft_ray_local	48m ago

随后在lab13中，我根据老师提供的代码框架进行了训练，下图是训练开始的截图：

```
print("\nRay 已关闭，演示结束。")


[*]: # ===== 运行训练 =====
      main()

2026-05-21 17:13:54,670 INFO worker.py:1998 -- Started a local Ray instance. View the dashboard at http://127.0.0.1:8265

[]:
```

(4)

下图是我的网页和测试demo：



Q2

(1) 本小问内容使用的LLM为deepseek，对话内容如下：

目前ChatGPT等模型的生图功能非常强大，人们有时已经难以分辨一张图片是否为AI生成，作为一家专注于 LLM 应用的盈利型初创公司，能否通过一些技术手段解决这一问题？你有什么好的思路建议？在你的回答中，标记出不确定的和未经验证没有现实证据支持的内容

☒ 已思考 (用时 28 秒) ▾

- 我们需要回应一个关于“LLM应用初创公司如何解决AI生图真假难辨问题”的咨询。用户要求回答中标记出“不确定的”和“未经验证没有现实证据支持的内容”。我需要提供思路建议，并思考如何标记。

关于你给出的五条手段，我认为1与普通LLM区别不大，3和5成本过高且效果不太明显，相比之下2和4似乎更有可行性，但是需要建立一个统一标准或者框架，而不是如C2PA一样的封闭式系统。但是作为初创公司，不太可能有能力来建立这样的框架，在此基础上还有什么办法吗

🔗 ✎

☒ 已思考 (用时 19 秒) ▾

- 我们被要求提供关于初创公司围绕“AI生成图片鉴别”这个痛点的建议。用户对前面提出的五条手段做了反馈：认为1（被动检测）与普通LLM区别不大，3（内容逻辑分析）和5（信誉网络）成本高效率不明显，而2（主动水印与来源验证）和4（链上溯源）更有可行性，但需要建立统一标准或框架，不能是C2PA那样的封闭式系统。用户指出初创公司不太可能建立这样的框架，问在此基础上还有什么办法。

随后LLM提出了这样一个思路，我认为对于初创公司来说比较可行，且赛道上已有竞争对手较少：

4. 提供“全链路溯源模拟验证”服务，构建透明度的信任分

既然你不能强制所有图片都内嵌水印，那么可以为那些愿意自证清白的创作者或媒体，提供一套完整的溯源背书。

流程：

1. 你为创作者提供一个桌面端工具，它能在生成/编辑图片时自动截图记录整个屏幕操作过程（类似游戏高光录像），并生成一个加密的“创作过程凭证包”（含屏幕录像缩略片段、关键帧哈希、时间戳）。
2. 创作者将凭证上传到你的去中心化存储网络。
3. 用户查看图片时，可通过你的浏览器插件查看“创作过程摘要”，了解它是否来自 AI 工具。

这样，你构建的其实是一个自愿透明度体系，而不是一个强制检测系统。但它会逐渐形成“有凭证的图片更可信”的认知，倒逼更多创作者加入。

基于此思路的商业计划书和路演ppt见Q2_1相关文件

(2)

架构设计文档见相关文件，下面是一个总体架构图：

