



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

STA303 Artificial Intelligence Course Project

黄俊翔，王洛源，汪楚瑜



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

目录

CONTENTS

01

ddqn



02

PPO



03

DAgger





南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

01

ddqn



ddqn原参数：——继承原dqn参数

GAMMA = 0.99

LR = 1e-3

BATCH_SIZE = 32

MEMORY_SIZE = 50_000

INITIAL_EXPLORATION_STEPS = 1_000

EPS_START = 1.0

EPS_END = 0.05

EPS_DECAY = 0.995

TARGET_UPDATE_STEPS = 500


核心逻辑（experience_replay方法）：

原 DQN 是直接target网络选动作 + 算 Q 值：

```
q_next = self.target(s2_t).max(dim=1,  
keepdim=True)[0];
```

DDQN 改为：用online网络选动作（next_actions = self.online(s2_t).argmax(...))，再用target网络算该动作的 Q 值（q_next = self.target(s2_t).gather(...)）。

CartPole-v1 - Training Progress



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

初始未调参图像:
探索率过早衰减
模型未完全收敛

调整参数:

$\text{GAMMA} = 0.99$

$\text{LR} = 7\text{e-}4$

微降学习率

$\text{BATCH_SIZE} = 64$

增大批次

$\text{MEMORY_SIZE} = 50_000$

$\text{INITIAL_EXPLORATION_STEPS} = 500$ # 缩短预热


$\text{EPS_START} = 1.0$

低最终探索率

$\text{EPS_DECAY} = 0.996$

加快探索衰减

$\text{TARGET_UPDATE_STEPS} = 200$ # 核心调整: 目标网络
每200步更新一次




调参过后训练结果

评估结果:

[Eval] Average over 100 episodes: 500.00



潜在问题：结果得分不稳定，受强化学习随机性影响极大



相同代码的第二次训练：
评分低，能上500但是无法保持

解决方法：

- 1、调整参数
- 2、延长训练轮次至2000

最终调参：

$\text{GAMMA} = 0.99$

$\text{LR} = 5\text{e-}4$

$\text{BATCH_SIZE} = 64$

$\text{MEMORY_SIZE} = 100_000$


$\text{INITIAL_EXPLORATION_STEPS} = 1000$

$\text{EPS_START} = 1.0$

$\text{EPS_END} = 0.05$

$\text{EPS_DECAY} = 0.999$

$\text{TARGET_UPDATE_STEPS} = 500$



即使1750附近有回落，也可迅速调整回到高值





南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

02

PP0



最初设想：套用ddqn训练代码，调整PPO逻辑与参数



[PPO-Eval] Average over 100 episodes: 70.41

瓶颈：

调整参数解决问题——失败

优化奖励增减——失败

固定种子，优化为纯贪心算法——失败

降低更新步数门槛——失败

问题探究：算法级逻辑冲突，PPO原理被破坏

可能引发问题原因：PPO的训练函数参照原ddqn算法，引入的逻辑与原PPO冲突

PPO 不应该再用 ϵ -greedy / explore_decay

reward shaping 破坏了 on-policy 优势估计

rollout 更新触发条件 + act / logp 存储方式极其脆弱

PPO 是 on-policy 方法，因此训练阶段必须始终从当前策略分布中采样动作。

引入 ϵ -greedy 或 deterministic action 会破坏 importance sampling ratio，导致策略更新偏离理论假设。

解决方法:

删除 explore_decay 相关逻辑

训练阶段使用原始 reward

rollout 更新条件统一

降低 PPO 更新强度

最终调参:

gamma: float = 0.99

lam: float = 0.95

lr: float = 1e-4

rollout_len: int = 256

update_epochs: int = 4

minibatch_size: int = 64

max_grad_norm: float = 0.5

clip_eps: float = 0.05


vf_coef: float = 0.5

ent_coef: float = 0.001

hidden_sizes: Tuple[int, int] = (64, 64)

adv_norm: bool = True

CartPole-v1 - Training Progress






南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

03

DAgger



Behavioral Cloning: 一种模仿学习 (Imitation Learning) 方法，核心思想是让智能体通过学习专家的示范数据 (状态 - 动作对)，直接模仿专家的行为策略。



回报率较低

DAgger: 数据集聚合的模仿学习

DAgger 的核心是迭代收集数据 + 有监督训练:

初始阶段: 收集专家在环境中的示范数据 (状态 $\rightarrow$ 专家动作), 训练初始策略 π_0 ;


迭代阶段:

用当前策略 π_k 与环境交互, 收集策略产生的状态序列 S_k ;

让专家对 S_k 中每个状态标注“最优动作”, 将 (S_k , 专家动作) 加入数据集;

用聚合后的数据集 (包含历史所有专家标注数据) 重新训练策略 π_{k+1} ;

终止条件: 策略性能收敛或达到迭代次数。



最终专家参数:

```
def expert_annotate(state):  
    angle, ang_vel = state[2],  
    state[3]  
    if angle + 0.1 * ang_vel < 0:  
        return 0  
    else:  
        return 1
```

得分: 500

DAgger和DQN比较

维度	DAgger (Dataset Aggregation)	DQN (Deep Q-Network)
算法归属	模仿学习 (IL) → 离线模仿学习 (数据集聚合类), 属于有监督式的策略学习	强化学习 (RL) → 无模型值函数逼近, 属于试错式的策略学习
核心目标	从专家示范 (Expert Demonstrations) 中学习最优策略, 解决 RL 探索效率低的问题	从与环境的交互试错中学习价值函数, 逼近最优 Q 值, 进而得到最优策略
核心假设	存在高质量的专家策略 / 示范数据, 且专家策略接近最优	环境可交互、奖励信号可观测, 通过试错探索能逐步逼近最优策略



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

南方科技大学 感谢您的观看与收听

THANK YOU FOR WATCHING AND LISTENING

