



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

考试科目: 多元统计分析 开课单位: 统计与数据科学系

考试时长: 2 小时 命题教师: 蒋学军

题号	1	2	3	4	5	6	7	8	9	10
分值										

本试卷共(五)大题, 满分(100)分(考试结束后请将试卷、答题卡、草稿纸一起交给监考老师)
INSTRUCTIONS: This is a closed book exam. Examination time is 2.0 hours. There are five sections. Attempt all questions and write down your answers to all questions in the test in separate blank. You may use a scientific calculator. You can write down your answers in Chinese or in English. Please write neatly and legibly.

一、填空题(24 分)

1. 设 $x_1, x_2, \dots, x_n$ 是来自多元正态总体 $N_p(\mu, \Sigma)$ 的一个样本, 当 Σ 未知时, 欲检验 $H_0: \mu = \mu_0$ 或 $H_1: \mu \neq \mu_0$ 构造的 Hotelling 统计量 $T^2 = n(\bar{x} - \mu_0)' S^{-1}(\bar{x} - \mu_0)$ 具有性质: $[(n-p)T^2]/[p(n-1)]$ 服从自由度为 p 和 n-p 的 F 分布
2. 设 $x_1, x_2, \dots, x_n$ 是取自多元正态总体 $N_p(\mu, \Sigma)$ 的一个样本, Σ 未知, 样本均值为 $\bar{x}$, 样本协方差矩阵为 S , 设样本协方差矩阵 S 的特征值依次为 $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p$, 相应的正交特征向量为 $\hat{t}_1, \hat{t}_2, \dots, \hat{t}_p$. 选取较小的因子数 m 使得累计贡献率 $\sum_{i=1}^m \hat{\lambda}_i / \sum_{i=1}^p \hat{\lambda}_i$ 达到一个较高的百分比, 此时 $\hat{\lambda}_{m+1}, \dots, \hat{\lambda}_p$ 一般已相对较少, 则因子载荷矩阵 A 的主成分分解 $\hat{A}$ 可表示为 $\hat{A} =$ (____, _____, _____), 即写出 $\hat{A}$ 的第 1 列, 第 2 列和第 m 列的表达。
3. 上述因子载荷矩阵 $\hat{A}$ 的第 j 列与从 S 出发求得的第 j 个主成分的系数向量____仅相差一个倍数____ ($j = 1, 2, \dots, m$)。
4. 假设原始变量 $x = (x_1, x_2, \dots, x_p)'$ 的各个分量都已标准化, 则因子分析中因子载荷系数 a_{ij} 表示的统计意义是_____。
5. 假设 $X = (x_1, x_2, x_3, x_4)'$ 的相关矩阵 R 为

$$R = \begin{bmatrix} 1.000 & -0.706 & -0.231 & 0.719 \\ -0.706 & 1.000 & 0.454 & -0.872 \\ -0.231 & 0.454 & 1.000 & -0.075 \\ 0.719 & -0.872 & -0.075 & 1.000 \end{bmatrix},$$

已知相关矩阵 R 可分解为

$$R = \begin{bmatrix} 0.667 & -0.333 \\ -0.77 & 0.577 \\ 0.139 & 0.971 \\ 0.971 & -0.216 \end{bmatrix} \begin{bmatrix} 0.667 & -0.77 & 0.139 & 0.971 \\ -0.333 & 0.577 & 0.971 & -0.216 \end{bmatrix} + \text{diag}\{1.333, 0.385, 0.277, 0.108\}$$

那么 x_2 的共性方差 $h_2^2 = \underline{\hspace{2cm}}$, 公共因子 f_2 对原始变量 x_1, x_2, x_3, x_4 总方差的贡献 $g_2^2 = \underline{\hspace{2cm}}$ 。

6. 费希尔判别的基本思想是降维, 费希尔判别需假定原始变量各个组的协方差相同, 借助投影的方法, 利用一元方差分析中的 F-统计量最大使得各个组均值之间的差异最大, 实际上隐含假设总体服从 分布。
7. 假设 Σ 是 $X = (x_1, x_2, \dots, x_p)'$ 的总体协方差矩阵, $\lambda_1 \geq \dots \geq \lambda_p$ 是 Σ 的特征值, $t_i = (t_{i1}, t_{i2}, \dots, t_{ip})', i = 1, 2, \dots, p$ 是相应的特征向量, 则原始向量 X 第一个主成分 $y_1 = \underline{\hspace{2cm}}$, 并且 $\text{var}(y_1) = \underline{\hspace{2cm}}$ 。
8. 对于两组的判别 (组数=2 时的费希尔判别), 费希尔 (Fisher) 判别等价于 相等时的距离判别; 对两个正态组, 费希尔 (Fisher) 判别等价于协方差矩阵相等且先验概率和 均相同时的贝叶斯判别。

二、单项选择题: (18 分, 从每小题所列备选答案中选择一个正确的, 将其代号填在题后面的括号中。共 6 小题, 每小题 3 分)

1. 设 Σ 为对称矩阵, 则 Σ 的迹(trace)为 ()。

A Σ 的非负特征值的个数
B Σ 的非零特征值的个数

C Σ 的所有特征值之和
D Σ 的所有特征值的乘积
2. 设 $x_1, x_2, \dots, x_n$ 是取自 $N_p(\mu, \Sigma), \Sigma > 0$ 的一个样本, 则样本离差阵 $(n-1)S$ 服从的分布是 ()。

A $W_p(n-1, \Sigma)$
B $W_p(n, \Sigma)$
C Wilks 分布
D F 分布
3. 利用主成分分析得到的各个主成分之间 ()。

A 相互独立
B 互不相关
C 线性相关
D 不完全相关
4. 下面哪一项不是聚类分析方法 ()。

A 费希尔判别
B 最短距离法
C 类平均法
D 重心法
5. 下面关于正交因子旋转描述不正确的是 ()。

A 公共因子的正交旋转等价于对因子载荷矩阵作一个正交变换使得旋转后的因子载荷矩阵在每一列的元素的绝对值尽量地大小拉开, 目的是能更好地解析公共因子。

B 正交旋转不改变共性方差。
C 正交旋转不改变残差矩阵。
D 正交旋转不改变因子载荷矩阵的估计。
6. 下列说法中可能正确是 ()。

- A 费希尔判别对总体没有任何要求
- B 公共因子是可以观测的
- C 不同的系统聚类方法的区别在于定义类之间的距离不一样
- D 主成分分析要求变量服从正态分布

三、简答题（20 分）

- 1.（12 分）请阐述主成分分析和因子分析的基本思想(2 分)，方法步骤(6 分)，比较其异同(4 分)。
- 2.（8 分）请写出
 - 1) 正交因子模型及其需要的假设；(4 分)
 - 2) 说明正交因子模型的因子载荷矩阵的估计不唯一。(4 分)

四、计算及分析题（30 分）

- 1.（8 分）.设有 5 个样品，每个只测一个指标，分别是 1, 2, 6, 8, 11，试用类平均法将它们作系统聚类，并画出树形图（请保留过程），根据树形图你觉得分成几类比较好。注意本题的类与类的距离定义为所有样品对之间的平均距离，即定义 G_k 和 G_l 之间的距离为

$$D_{kl} = \frac{1}{n_k n_l} \sum_{i \in G_k, j \in G_l} d_{ij},$$

其中 n_k 和 n_l 分别是类 G_k 和类 G_l 的样品的个数, d_{ij} 为 G_k 中的样品 i 与 G_l 中的样品 j 之间的距离。

2. (10 分) 设 $\mathbf{x} = (x_1, x_2, \dots, x_p)'$ 的相关矩阵为

$$R = \begin{bmatrix} 1 & 0.5 & \cdots & 0.5 \\ 0.5 & 1 & \cdots & 0.5 \\ \vdots & \vdots & \ddots & \vdots \\ 0.5 & 0.5 & \cdots & 1 \end{bmatrix}.$$

该相关矩阵常用于描述诸如生物大小等生态学变量之间的对应关系，试求 R 的特征值(3 分)、（正交化的单位）特征向量（4 分）及每个主成分的贡献率（3 分）。

3. (12 分). (消费者倾向数据因子分析) 在消费者倾向性调查中，某公司调查人员随机调查一批顾客对该公司某一新产品的几个属性进行评分，并将搜集到的评分制成表格，从而构造出该新产品几个属性的样本相关矩阵如下：

Attribute (Variable)		1	2	3	4	5
Taste	1	1.00	.02	.96	.42	.01
Good buy for money	2	.02	1.00	.13	.71	.85
Flavor	3	.96	.13	1.00	.50	.11
Suitable for snack	4	.42	.71	.50	1.00	.79
Provides lots of energy	5	.01	.85	.11	.79	1.00

请根据 SAS 程序的输出结果回答下面的问题。

1) 作者为什么只选择两个公共因子? (2 points)

2) 通过对相关矩阵R 进行分解

$$R = AA' + D,$$

这里A是因子载荷矩阵，对角矩阵D是特殊因子向量的协方差矩阵。根据上述分解，我们得到下述方程

$$\begin{bmatrix} 0.56 & 0.82 \\ 0.78 & -0.53 \\ 0.65 & 0.75 \\ 0.94 & -0.10 \\ 0.80 & -0.54 \end{bmatrix} \begin{bmatrix} 0.56 & 0.78 & 0.65 & 0.94 & 0.80 \\ 0.82 & -0.53 & 0.75 & -0.10 & -0.54 \end{bmatrix} + \hat{D}$$

$$= \begin{bmatrix} 1.00 & 0.01 & 0.97 & 0.44 & 0.00 \\ 0.01 & 1.00 & 0.11 & 0.79 & 0.91 \\ 0.97 & 0.79 & 1.00 & 0.53 & 0.11 \\ 0.79 & 0.11 & 0.53 & 1.00 & 0.81 \\ 0.00 & 0.44 & 0.11 & 0.81 & 1.00 \end{bmatrix}$$

其中 $\hat{D} = \text{diag}\{\hat{\sigma}_{11}^2, \hat{\sigma}_{22}^2, \hat{\sigma}_{33}^2, \hat{\sigma}_{44}^2, \hat{\sigma}_{55}^2\}$ 是特殊因子向量协方差矩阵的D的估计。请根据上述方程计算特殊因子方差的估计 $\hat{\sigma}_{ii}^2$ ($i = 1, 2, 3, 4, 5$)。 (5 points)

3) 请阐述因子旋转的目的。 (3 points)

4) 根据旋转后的因子载荷矩阵，请解析公共因子1和公共因子2的含义。(2 points)

The outputs by SAS programming

```

title 'Factor Analysis';
data consumer(type = corr);
_type_='CORR';
input _name_$ taste money flavor snack energy;
cards;
taste      1.00      .      .      .      .
money      .02      1.00      .      .      .
flavor     .96      .13      1.00      .      .
snack      .42      .71      .50      1.00      .
energy     .01      .85      .11      .79      1.00
;
proc factor res data=consumer
  method=prin nfact=2rotate=varimax preplot plot;
var taste money flavor snack energy;

```

PROGRAM COMMANDS

Initial Factor Method: Principal Components

OUTPUT

Prior Communality Estimates: ONE

Eigenvalues of the Correlation Matrix: Total = 5 Average = 1

	1	2	3	4	5
Eigenvalue	2.853090	1.806332	0.204490	0.102409	0.033677
Difference	1.046758	1.601842	0.102081	0.068732	
Proportion	0.5706	0.3613	0.0409	0.0205	0.0067
Cumulative	0.5706	0.9319	0.9728	0.9933	1.0000

2 factors will be retained by the NFACTOR criterion.

Factor Pattern

	FACTOR1	FACTOR2
TASTE	0.55986	0.81610
MONEY	0.77726	-0.52420
FLAVOR	0.64534	0.74795
SNACK	0.93911	-0.10492
ENERGY	0.79821	-0.54323

Final Communality Estimates: Total = 4.659423

TASTE	MONEY	FLAVOR	SNACK	ENERGY
0.97961	0.878920	0.975883	0.892928	0.932231

Rotation Method: Varimax		
Rotated Factor Pattern		
	FACTOR1	FACTOR2
TASTE	0.01970	0.98948
MONEY	0.93744	-0.01123
FLAVOR	0.12856	0.97947
SNACK	0.84244	0.42805
ENERGY	0.96539	-0.01563
Variance explained by each factor		
	FACTOR1	FACTOR2
	2.537396	2.122027

五、证明题（8分）

(加权最小二乘估计, WLSE.) 考虑线性模型

$$Y_{n \times 1} = Z_{n \times (r+1)} \beta_{(r+1) \times 1} + \varepsilon, \quad (1)$$

这里 ε 服从 n 元正态分布, 且 $E(\varepsilon) = 0$, $E(\varepsilon \varepsilon') = \sigma^2 V$, $V(n \times n)$ 是一个已知的正定矩阵。因为上述模型的误差是相关, 所以线性模型 (1) 不是经典的线性模型。然而, 我们可以对 V 做分解 $V = KK'$, 并考虑 Y 的转换 $K^{-1}Y$ 。于是, 我们有下述模型

$$K^{-1}Y = K^{-1}Z\beta + K^{-1}\varepsilon.$$

令 $Y^* = K^{-1}Y, Z^* = K^{-1}Z, \varepsilon^* = K^{-1}\varepsilon$, 重新表述上述模型为

$$Y^* = Z^*\beta + \varepsilon^*. \quad (2)$$

这里, $\varepsilon^* \sim N_r(0, \sigma^2 I)$ 满足经典线性回归模型误差独立同分布的条件。我们称从模型 (2) 得到的最小二乘估计为模型 (1) 的加权最小二乘估计。证明加权最小二乘估计的表达式为

$$\hat{\beta}_w = (Z'V^{-1}Z)^{-1}Z'V^{-1}Y. \quad (4 \text{ 分})$$

if σ^2 未知, $(n-r-1)^{-1} \times (Y - Z\hat{\beta}_w)' V^{-1} (Y - Z\hat{\beta}_w)$ 是 σ^2 的一个无偏估计。(4 分)