

PPT 第 1 页：标题页

各位老师、同学大家好，我们小组汇报的题目是“**证券投资策略与客户交易画像的精准匹配研究**”。

PPT 第 2 页：目录

本次汇报主要分为五个部分。

第一部分是一个project overview；第二部分是数据和特征构造；第三部分是多元分析与聚类；第四部分是客户—策略匹配结果；最后是总结和未来工作。

PPT 第 3–7 页：Project Overview

首先是我们的第一部分 project overview

PPT 第 4 页：研究动机

首先介绍项目动机。

量化策略之间存在明显差异。例如，不同策略的选股逻辑、交易频率、持仓周期、持仓集中度、波动和回撤控制能力都不一样。有的策略更偏向高频交易，有的策略更偏向长期持有；有的策略收益弹性较高，但波动也更大；有的策略则更稳健。

另一方面，客户之间也存在差异。不同客户的风险偏好、交易行为和投资风格并不相同。有些客户交易频率高，有些客户更倾向于低频持有；有些客户能承受较大的波动，有些客户则更关注回撤控制。

因此，我们认为一个有意义的策略推荐系统，不应该只推荐历史收益最高的策略，而应该同时满足两个条件：第一，策略风格要和客户历史交易风格比较接近；第二，策略的收益和风险表现要优于客户自己的历史表现。

PPT 第 5 页：研究问题

基于这个动机，我们提出三个研究问题。

第一，能否从策略和客户的交易记录中提取出有经济含义的特征？

第二，客户和策略在多变量特征空间中是否能够形成相对稳定、可解释的分组？

第三，能否建立一个同时考虑风格相似性和绩效提升的匹配模型？

这三个问题对应了我们后续的完整流程：先构造特征，再做降维和聚类，最后进行客户—策略匹配。

PPT 第 6 页：项目整体设计

本项目的目标是建立一个可解释、数据驱动的量化策略匹配框架。

在数据方面，我们一共使用了 20 个量化策略、3 个真实客户和 25 个模拟客户，总共 48 个分析对象。每个对象都构造了 18 个特征，这些特征覆盖交易行为、持仓结构和收益风险表现三个方面。

在方法方面，我们首先使用 PCA 总结主要变化方向；然后用 K-means、层次聚类和高斯混合模型来检验分组稳定性；LDA 只用于可视化，不作为独立验证方法；最后，我们建立了一个两阶段匹配模型，把风格相似度和绩效优势结合起来，得到最终推荐结果。

PPT 第 7 页：主要结果概览

这里先给出项目的主要结果。

PCA 结果显示，第一主成分解释了 44.41% 的总方差，前五个主成分累计解释了 80.38% 的总方差。这说明我们的特征空间存在明显的共同结构。

聚类结果方面，K-means 和层次聚类之间的 ARI 为 0.8438，K-means 和 GMM 之间的 ARI 为 0.9699，说明不同聚类方法得到的结果高度一致，分组结构比较稳定。

最终推荐结果是：客户 A 推荐双创 50 增强策略，得分 0.4810；客户 B 推荐医疗 ETF 增强策略，得分 0.4341；客户 C 推荐中证 2000 增强策略，得分 0.5620。对三个真实客户来说，推荐策略在收益和最大回撤两个指标上都有改善，因此这个框架可以看作一个探索性但可行的原型。

PPT 第 8–12 页：Data and Feature Construction

然后是我们的第二部分数据和特征构造

PPT 第 9 页：数据构造

由于真实客户数量有限，我们只有 3 个真实客户。如果只基于这 3 个客户进行分析，样本空间会非常小，也很难检验方法是否具有区分能力。因此，我们额外构造了 25 个模拟客户，用于扩展方法测试空间。

最终样本包括 20 个量化策略、3 个真实客户和 25 个模拟客户，总共 48 个实体。这里需要强调的是，模拟客户的作用是帮助我们测试方法流程，而不是证明真实投资者群体的分布。因此，本项目的结论更适合被理解方法原型，而不是生产级系统。

PPT 第 10 页：特征体系

我们构造的特征体系分为三类。

第一类是交易行为特征，例如对数交易频率、平均持有天数和换手率。这类特征主要反映客户或策略的交易活跃程度。

第二类是持仓结构特征，例如买卖比例、股票数量、集中度和平均持仓比例。这类特征反映投资对象是否分散、持仓是否集中。

第三类是收益风险表现特征，例如平均收益率、胜率、盈亏比、最大回撤、波动率和类 Sharpe 比率。这类特征反映投资结果的质量。

PPT 第 11 页：重要数据假设

这里有一个重要限制需要说明。

策略端的数据相对完整，策略的年化收益率和最大回撤主要来自策略汇总表，交易级数据则用于估计胜率、波动率等指标。

但是客户端没有完整的每日账户净值曲线。因此，客户的收益、回撤和类 Sharpe 指标不能直接精确计算，只能通过 FIFO 匹配交易记录进行近似估计。

这意味着客户端绩效指标存在一定误差，所以后续匹配结果不能被解释为严格的投资结论，而应被理解为基于现有交易记录的近似分析。

PPT 第 12 页：模拟客户设计

模拟客户主要分为五类。

第一类是保守防御型，特征是交易频率较低、持仓较稳定、波动较小。

第二类是均衡配置型，特点是适度分散和中等交易频率。

第三类是高频交易型，特点是换手率更高、持有周期更短。

第四类是成长激进型，通常承担更高波动，以追求更高潜在收益。

第五类是集中持仓型，特点是持股数量较少、集中度较高。

这些类型的设定，使得客户样本在交易行为和风险偏好上具有更丰富的差异，方便后续检验模型是否能识别不同风格。

PPT 第 13–22 页：Multivariate Analysis and Clustering

然后是第三部分 多元分析与聚类

PPT 第 14 页：标准化与 PCA

在进行 PCA 和聚类之前，我们先对所有数值变量进行标准化。原因是不同特征的单位 and 尺度差异很大。如果不标准化，基于距离的方法会被数值尺度较大的变量主导。

PCA 的作用主要有三个：第一，总结高维特征之间的相关结构；第二，把主要变化方向可视化；第三，为后续聚类提供解释基础。

PPT 第 15 页：相关结构

从相关性热力图可以看到，18 个变量之间存在明显相关性。例如，一些交易活跃度相关变量会同向变化，而一些风险收益指标之间也存在联系。

但这些变量并不是完全冗余的。也就是说，特征体系既有结构，又保留了多维信息。这支持我们使用 PCA 来提取主要变化方向，同时也说明不能简单只保留单个指标。

PPT 第 16 页：PCA 解释方差

这一页展示了前五个主成分的解释方差。

第一主成分解释 44.41%，第二主成分解释 15.23%，前两个主成分合计解释 59.64%。前五个主成分累计解释 80.38%。

这个结果说明，客户和策略的特征差异中有相当一部分可以被少数主成分概括，但仍然存在多维结构。

PPT 第 17 页：PCA 投影

从 PCA 投影图可以看到，真实客户和模拟客户整体比较集中，而策略点分布更加分散。

这说明策略之间的风格差异更明显，而客户样本，特别是模拟客户，是围绕若干设定类型形成的相对集中区域。

从解释上看，PC1 主要反映规模、活跃度和收益风险概况；PC2 则有助于区分波动率和持仓集中度方面的风格差异。

PPT 第 18 页: PCA Loading Plot

Loading plot 用来解释主成分的经济含义。

如果两个特征箭头方向相近，说明它们在主成分空间中正相关；如果方向相反，则说明它们倾向于负相关。箭头长度越明显，说明这个变量对主成分方向的贡献越大。

PPT 第 19 页: 聚类方法

在聚类部分，我们比较了三种方法。

K-means 是主要分组方法；层次聚类用于稳健性比较；高斯混合模型则提供一种概率式的替代视角。

这样做的出发点是：如果不同算法得到的分组结果高度一致，那么聚类结构就不太可能只是某一个算法的偶然产物，而更可能反映了特征空间中相对稳定的分组模式。

PPT 第 20 页: 聚类数量选择

这一页展示了不同 K 值下的聚类评价指标。

从 Silhouette 指标看，K=3 的结果最高，为 0.4203；从 Davies-Bouldin 指标看，K=4 最优，为 0.7337。虽然两个指标的最优值不完全一致，但 K=3 的数值表现仍然有竞争力，并且更容易解释。

因此，我们最终保留 K=3 作为主要聚类数。

PPT 第 21 页: 聚类稳健性

为了检验聚类稳定性，我们计算了不同聚类方法之间的 ARI。

K-means 和层次聚类之间的 ARI 是 0.8438，K-means 和 GMM 之间的 ARI 是 0.9699。ARI 越接近 1，说明两个聚类结果越一致。

这个结果说明，不同方法得到的分组高度相似，因此客户和策略在特征空间中确实存在较稳定的群组结构。

PPT 第 22 页: LDA 可视化

最后，我们使用 LDA 进行可视化。

从图中可以看到，客户点相对集中，而部分策略远离中心区域。这与 PCA 投影中的观察一致：客户交易画像相对集中，而策略风格更加分散。

PPT 第 23–29 页：Client-Strategy Matching Results

接下来是第四部分 客户—策略匹配结果。

PPT 第 24 页：两阶段匹配模型

我们设计了一个两阶段匹配模型。

第一阶段计算风格相似度。风格得分由行为相似度和持仓相似度组成，其中行为相似度权重为 0.45，持仓相似度权重为 0.55。

第二阶段计算绩效优势，主要比较收益率、类 Sharpe 比率、最大回撤和波动率。

最终得分由两部分加权得到：风格得分权重为 0.7，绩效得分权重为 0.3。这样设计的原因是，我们希望推荐结果首先和客户风格相近，同时也要体现收益风险改善。

PPT 第 25 页：匹配得分热力图

这一页是匹配得分热力图。

行代表三个真实客户，列代表候选策略，颜色代表最终匹配分数。

可以看到，不同客户的高分策略并不完全相同。这说明风格匹配部分确实起到了区分客户的作用。

PPT 第 26 页：Top 推荐结果

这一页展示三个真实客户的最高推荐策略。

客户 A 的最高推荐是双创 50 增强策略，最终得分为 0.4810，收益改善为 1.1015，回撤改善为 0.2580。

客户 B 的最高推荐是医疗 ETF 增强策略，最终得分为 0.4341，收益改善为 0.2115，回撤改善为 0.8010。

客户 C 的最高推荐是中证 2000 增强策略，最终得分为 0.5620，收益改善为 0.6706，回撤改善为 0.3372。

关键结论是，三个客户得到的推荐策略不同，而且每个客户的推荐策略都同时改善了收益和最大回撤。

PPT 第 27 页：Top-5 推荐

这一页展示每个客户的 Top-5 推荐策略。

PPT 第 28 页：风格匹配与绩效改善的权衡

这一页进一步展示了风格匹配和绩效改善之间的关系。

有些策略与客户风格更接近，但绩效提升未必最大；有些策略绩效改善更明显，但风格差异可能更大。

这说明推荐策略时存在一个 trade-off。实际业务中，不一定应该选择收益最高的策略，而是需要在客户接受度、风险承受能力和绩效改善之间取得平衡。

PPT 第 29 页：统计检验

为了进一步观察聚类结果是否具有经济含义，我们使用 Kruskal-Wallis 检验比较不同聚类在部分特征上的差异。

需要强调的是，Kruskal-Wallis 检验不能证明因果关系，也不能证明聚类一定是真实市场结构。但它能说明，不同聚类在一些有经济含义的变量上确实存在统计差异。

结果显示，胜率、持仓峰值比例、收益波动率和股票数量等变量的 p-value 小于 0.05，说明这些变量在不同聚类之间存在显著差异。类 Sharpe 比率的 p-value 为 0.0894，也表现出一定差异趋势。

PPT 第 30–34 页：Conclusion and Future Work

最后我们进行总结

PPT 第 31 页：主要发现总结

首先是本项目的主要发现

第一，我们构造的特征体系能够捕捉客户和策略之间的有意义差异。

第二，K=3 的聚类结果具有较好的稳定性和解释性。

第三，K-means、层次聚类和 GMM 三种方法得到的结果高度一致，说明分组结构比较稳健。

第四，两阶段匹配模型能够产生客户特定的策略推荐结果。

第五，对于三个真实客户，最高推荐策略都同时改善了收益和最大回撤。

PPT 第 32 页：局限性

本项目也存在一些重要局限。

第一，真实客户数量只有 3 个，样本规模较小。

第二，模拟客户主要用于方法扩展，不能代表真实投资者分布。

第三，客户侧绩效指标是近似估计的，因为缺少完整每日账户净值曲线。

第四，匹配权重是规则设定的，不是从真实客户接受行为或未来投资表现中学习得到的。

因此，目前模型更适合作为探索性分析框架，而不是直接用于实际部署。

PPT 第 33 页：未来工作

未来可以从几个方向改进。

第一，收集更多真实客户账户数据，提高样本代表性。

第二，使用完整的每日账户净值曲线，更准确地计算收益、回撤和风险指标。

第三，加入更丰富的行业偏好和板块暴露变量，使客户画像更细致。

第四，从历史推荐结果中学习匹配权重，而不是人工设定权重。

第五，用样本外未来表现来评估推荐策略是否真正有效。

PPT 第 34 页：最终结论

总体来说，我们构建了一个可解释的客户—量化策略匹配流程。这个流程结合了特征工程、PCA、聚类、LDA 可视化和两阶段匹配模型。

结果显示，客户和策略在多变量特征空间中存在相对稳定的分组结构，并且模型能够给出客户特定的策略推荐。

不过，我们也认为这个模型目前应被理解为一个可行原型，而不是最终部署系统。但它证明了基于交易记录的客户画像和策略特征，可以被整合到同一个多元分析框架中，从而为个性化、可解释的策略推荐提供方法基础。

PPT 第 35 页：Thanks

以上就是我们小组的汇报，谢谢各位老师和同学。欢迎大家提出问题。