

Assignment1 Report

12312515 王洛源

Part1. Baseline

首先，我使用给定的dataset.py文件对数据集进行初步处理，随后以lab3的相关代码为基础，进行简单修改后作为baseline。完成训练后，结果如下：

```
Epoch [10/10] Train Loss: 4.0000 | 11
Best Val Acc: 0.0436
Test Loss: 4.7595 | Test Acc: 0.0392
```

可以看出，训练集准确率与验证集准确率均较低，训练 10 个 epoch 后训练准确率最高约为 3.77%，验证准确率最高约为 4.36%。这表明当前基线模型虽然已经能够从数据中学习 to 一定信息，但整体性能仍然较弱，需要进一步调整参数。

Part2. 超参数调整

1.调整输入尺寸

```
Best Val Acc: 0.1635
Test Loss: 3.4215 | Test Acc: 0.1512
```

在完成初始 baseline 实验后，为了分析影响模型性能的关键因素，本实验首先只调整了输入图像尺寸这一项，其余超参数保持不变，从而进行单变量对比分析。具体而言，本轮实验仅**将图像预处理中的缩放尺寸由 224×224 修改为 64×64** ，此时输入维度降为 $64 \times 64 \times 3 = 12288$ 。实验结果表明，此时验证集最佳准确率提升至 0.1635，测试集准确率提升至 0.1512。该结果说明，在纯 MLP 图像分类任务中，输入维度对训练难度具有显著影响；适当降低输入分辨率能够有效减少模型第一层参数规模，从而改善训练稳定性和分类性能。

2.提升训练轮数，降低dropout

```
Best model saved.
Best Val Acc: 0.3962
Test Loss: 3.3660 | Test Acc: 0.3642
```

在前面的实验中，虽然通过降低输入图像尺寸，模型性能已有一定提升，但整体准确率仍然偏低，说明模型尚未充分拟合训练数据，存在欠拟合现象。因此，本轮实验在保持其余设置不变的情况下，**将训练轮数从 10 增加到 30，并将 MLP 中隐藏层后的 dropout 从 0.2 调整为 0.0**，以考察正则化强度对模型性能的影响。实验结果表明，这一调整带来了显著的性能提升。验证集最佳准确率由上一轮的 0.2371 提升至 0.3962，测试集准确率由 0.2038 提升至 0.3642。与此同时，训练损失显著下降，训练准确率提升至 0.6346，说明模型在移除 dropout 后获得了更强的拟合能力。

3.降低学习率

```
Best Val Acc: 0.4719
Test Loss: 2.8736 | Test Acc: 0.4606
```

本轮实验在保持其余设置不变的情况下，**仅将 Adam 优化器的学习率从 1×10^{-3} 调整为 3×10^{-4}** 。之所以进行这一调整，是因为前一阶段虽然模型已经能够充分学习，但验证集指标在训练后期仍存在一定波动，说明原始学习率可能偏大，导致参数更新步长过于激进，从而影响模型的后期收敛与泛化表现。实验结果表明，降低学习率后模型性能得到了显著提升。验证集最佳准确率提升至 0.4719，测试集准确率提升至 0.4606，均显著优于此前的实验结果。同时，训练过程中验证准确率整体呈较平稳上升趋势，说明较小的学习率使模型后期优化更加稳定。该结果表明，在当前纯 MLP 叶片分类任务中，学习率对模型最终性能具有显著影响；较小的学习率更适合当前网络结构和数据规模，能够有效改善模型的收敛质量与泛化性能。

在这一阶段后，我们尝试了添加 BatchNorm1d，降低 weight_decay，修改 Optimizer，增加输入尺寸，进一步降低学习率，降低隐藏层个数，引入 early stopping 机制等方法，模型最终性能均没有显著提升或反而出现下降。由于篇幅有限制，这里不给出结果的截图。

4. 加入学习率调度器

```
No improvement for 8 epoch(s).
Early stopping triggered at epoch 50.
Best Epoch: 42
Best Val Acc: 0.5264
Best Val Loss: 3.1220
Test Loss: 3.3079 | Test Acc: 0.4895
```

在确定较优模型结构与基础训练参数后，我们**引入了学习率调度器**，以实现前期较大学习率快速训练、后期自动降低学习率精细收敛的训练策略；同时结合 early stopping，在验证集连续若干轮无提升时停止训练，并保留验证集表现最佳的模型进行最终测试。实验结果表明，该策略使模型性能进一步提升。最佳验证集准确率提高至 0.5264，测试集准确率提高至 0.4895，说明学习率调度器能够改善后期收敛过程，使模型获得更好的验证集和测试集表现。与此同时，训练准确率接近 95%，而验证集与测试集准确率仍显著低于训练集，表明当前模型已经具备很强的训练集拟合能力，但存在过拟合问题，泛化性能仍然是主要瓶颈。

5. 修改损失函数

```
No improvement for 2 epoch(s).
Best Epoch: 48
Best Val Acc: 0.5640
Best Val Loss: 2.4690
Test Loss: 2.5939 | Test Acc: 0.5323
```

接下来，我们将**损失函数由标准交叉熵损失替换为带 label smoothing 的交叉熵损失**，即在训练时不再将真实类别视为概率为 1 的硬标签，而是用一个经过平滑处理的目标分布进行监督，从而降低模型对训练标签的过度自信。实验结果显示，模型最佳验证集准确率提高至 0.5640，测试集准确率提高至 0.5323，首次使测试集准确率超过 50%。这一结果说明，引入 label smoothing 后，模型在保持较强训练能力的同时显著改善了验证集与测试集表现。

6. 加入BN，提高dropout

```
No improvement for 8 epoch(s).
Early stopping triggered at epoch 75.
Best Epoch: 67
Best Val Acc: 0.6507
Best Val Loss: 1.9976
Metrics plot saved to metrics.png
Test Loss: 2.0728 | Test Acc: 0.6314
```

为了平衡过拟合问题，此时我们在mlp中再次加入了BN层，并将dropout提升为0.2，结果显示在控制过拟合程度的情况下，模型能在给定轮次内进一步学习，测试集准确率达到了0.6314，这说明这可能是一个重要的优化方向。但此后我们尝试了其他的降低过拟合方式，均无明显提升。

Part3. 评估和误差分析

本实验将 Top-1 Accuracy 作为主要评价指标，并同时报告 Macro-F1 作为辅助指标。主要原因是本任务是一个 176 类单标签图像分类问题，每张图像仅对应一个真实类别，因此 Accuracy 能直接反映模型整体分类正确率。此外，Macro-F1也可以作为补充。

最终，在 test set 上，本模型取得了：

- Accuracy = 0.6333
- Macro Precision = 0.6416
- Macro Recall = 0.6241
- Macro F1 = 0.6185

这说明模型不仅具有较好的整体分类能力，而且在类别平均意义下也取得了较为稳定的性能。从整体结果看，Accuracy 与 Macro-F1 的数值接近，但 Macro-F1 略低于 Accuracy，这表明模型虽然整体预测效果较好，但不同类别之间仍然存在一定的性能差异：有些类别已经能够被较稳定地区分，而另一些类别仍然更容易混淆。

从 confusion matrix 可以看出，矩阵主对角线整体较亮，说明大多数样本仍然被正确分类，这与测试集 Accuracy = 0.6333 的结果一致。与此同时，矩阵中仍存在不少离对角线较近的非零元素，说明错误并非随机分布，而是更倾向于发生在某些外观相似类别之间。

从错误样本图中可以观察到，错误样本具有几个共同特点：

1. 叶片较小，在整张图中的占比不高，导致有效形状信息不足；
2. 叶片外形相似，例如椭圆形或卵形叶片之间容易混淆；
3. 边缘与纹理信息较弱，在低分辨率输入下，细节差异被进一步削弱；
4. 某些样本中背景占比很大，而叶片主体相对较小，增加了判别难度。

这可能是由于输入被压缩，导致一些较为接近的类别更难区分的原因。也可能是纯MLP的局限所致。