

Assignment 3 Report

12312515 王洛源

本次作业，综合了数据集的大小、服务器的硬件配置等条件后，我选择使用第11周课上讲到的 Diffusion 模型为基础完成此次任务。该模型的原理是首先将训练集的图片数据进行正向扩散，一步步添加噪声，再让神经网络学习去掉噪声，尽量还原图像的过程。

在 baseline 阶段，我使用了如下超参设定：

```
image_size=64
batch_size=32
num_epochs=100
lr=2e-4
base_channels=64
```

并且使用AdamW优化器，没有使用数据增强。进行训练并调用评测程序进行打分，结果如下：

```
Feature weights: imagenet
/data/Assignment3/evaluate_fid.py:171: DeprecationWarning: The `disp`
  covmean, _ = linalg.sqrtm(sigma_real @ sigma_generated, disp=False)
FID: 389.2108
Metrics saved: /data/Assignment3/evaluation_results/fid_metrics.json
```

可以看得出这个FID得分相当高，并且我进行人工观察，发现生成的图片质量也很差，有大量的空白，少部分彩色区域也多是杂乱的斑点，说明模型需要进一步调整。

第一步调参，我首先对数据预处理进行了调整：针对训练图像“白色背景 + 单个陨石前景”的特点，在读取图像后先对前景区域进行裁剪，再保持长宽比缩放并补白到正方形画布。随后为避免所有训练样本都被处理成完全一致的构图模板，又进一步引入了随机主体尺度与轻微随机平移，从而使训练分布更接近原始数据分布。其次，在模型结构方面，将 U-Net 的基础通道数由 64 提升到 128，并在 16×16 特征层与 bottleneck 位置加入了 self-attention，以增强模型对全局轮廓和局部纹理关系的建模能力。再次，在扩散过程方面，将原本的线性 beta schedule 替换为 cosine schedule，并在反向采样中使用 posterior variance，从而提高了去噪过程的稳定性与采样质量。最后，在训练策略上，为适配更大的模型并提高训练稳定性，训练时降低了 batch size，并将学习率调整为更保守的设置，同时延长了训练轮数。综合上述改动后，模型生成结果虽然仍

以深色陨石区域为主、纹理细节仍有不足，但前景结构已明显优于初始 baseline，FID 也从389 降至 329，说明这些改进整体上是有效的。

```
cosine_annealing_lr, 1e-05
FID: 329.4184
Metrics saved: /data/1
```

随后，我们将原先的自实现教学版 U-Net / DDPM 框架替换为 diffusers 中更成熟的标准组件，FID分数进一步下降到303。此时生成的图片已经有明显的深色陨石主体区域，前景不再退化为纯白背景或零散色块。

```
cosine_annealing_lr, 1e-05
FID: 303.2981
Metrics saved:
```

第二步调参，我以当前已有模型权重为起点继续训练，并将学习率降低到更保守的范围，同时加入 CosineAnnealingLR 学习率调度器，使模型在已有粗轮廓基础上进一步细化前景结构、纹理与颜色分布。此外，为避免仅依赖最后一个 epoch 的结果，本轮训练过程中也保留了阶段性 checkpoint，以便后续比较不同训练阶段的生成效果。随后我将原先 DDIM 采样的步数从100 步提高到 250 步，使模型在生成阶段能够更充分地去噪。本次调参后，模型的 FID 从 303 进一步下降到 246。从生成结果来看，当前模型已经能够生成较完整的深色陨石主体，轮廓明显优于前几轮实验，背景噪声也有所减少，说明模型已逐步学到更合理的前景结构分布。

```
cosine_annealing_lr, 1e-05
FID: 246.3060
Metrics saved: /
```

第三步调参，我提升了训练与生成图像的分辨率到128，同时降低了batch size 以保证训练过程稳定运行。经过上述调整后，模型的 FID 显著下降到 138。从生成结果来看，图像已经能够形成较稳定的陨石主体，整体形状更自然，前景结构也比此前更加清晰。



随后，我降低了DDIM采样步数到200步，并降低了数据增强，使训练样本分布更加接近原始数据分布，继续训练120轮次后，模型的FID分数降低到121。

```
covmean, _ = 1
FID: 121.6687
Metrics saved: /
```

接下来，我选择继续减弱数据增强强度，仅保留最基本的几何扰动；同时在已有较优 checkpoint 的基础上，采用更小的学习率继续训练，以减少对已学到主体结构的破坏，并进一步细化纹理与边缘。继续训练80轮次后，模型的FID分数进一步降低到107。

```
FID: 107.3999
Metrics saved: /c
```

最后，我进一步提升了图像尺寸，FID分数来到了79.

```
covmean, _ =
FID: 79.2975
Metrics saved:
0.1504 0.0000
```

下图是我在训练过程中挑选出来的生成图像九宫格：



本次作业我的收获和反思主要有：

1. 在训练模型前应当先了解本次任务的硬件条件，并基于此设定合理超参。我借助AI设定的baseline没有充分利用服务器的硬件条件，导致前期训练明显偏慢且效果不佳
2. 对于图像处理和生成任务，尽量不要降低图像大小，这样会导致模型上限较低，学习效果也不够好
3. 在没有观测到明显的过拟合现象时，正则措施如数据增强和dropout可能反而会拖累训练，这些措施应当在存在过拟合现象时再考虑使用，而不是一开始就加入
4. 在训练后期需要适当调节学习率，使训练更加稳定