

Final Project

STA326

Department of Statistics and Data Science

March. 11, 2026

数据集说明

- **任务目标：**基于PyTorch深度学习框架识别陨石图像。
- **数据内容和类型：**数据集总共5609张标注图像。在此次项目中，我们专注识别图像是否为陨石。



非陨石





陨石




数据集构建

- **数据集结构：**分为训练集（5098张），测试集（511张）。训练集中非陨石与陨石样本数量约为1:1.11；测试集非陨石与陨石样本数量约为 4.06:1。



数据集使用

- 所有Project相关文件可直接在Kaggle中进行下载：
<https://kaggle.com/competitions/meteorite-identification/data>
- train_images中包含所有训练集图片，对应标签存放于train_labels.csv中用于本地训练和调参；test_images中包含所有无标签测试集图像。



数据集使用

- 如何加载数据集？dataset.py中给出具体代码示例。
- 最终需要提交文件格式是什么样的？如sample_submission.csv所示。
- 如何生成符合最终格式的提交文件？readme.md中给出详细讲解与代码教程。

meteorite-identification

Overview Data Code Models Discussion Leaderboard Rules Team Submissions Settings

Submit Prediction

dataset.py (3.78 kB)

About this file

This file does not have a description yet.

```
import os

import pandas as pd
from PIL import Image
from torch.utils.data import Dataset

def _require_file(path):
    if not os.path.exists(path):
        raise FileNotFoundError(f"{path} not found.")
    return path

def _load_csv(path, required_columns):
    df = pd.read_csv(_require_file(path))
```

Data Explorer

1.64 GB

- test_images
- test_images
- train_images
- dataset.py**
- readme.md
- sample_submission.csv**
- train_labels.csv

Summary

- 5613 files
- 4 columns

Download All

+ New Version

	id	label
1	000001.jpg	0
2	000002.jpg	0
3	000003.jpg	0
4	000004.jpg	0
5	000005.jpg	0

结果提交

- 最终分类效果在Kaggle上提交，指标为F1 Score。
- 项目将分为两阶段，并以第二阶段结果为最终成绩
 - 第一阶段以同分布测试集为主，提交地址为：
<https://www.kaggle.com/competitions/meteorite-identification>。截止时间为4月29日24:00
 - 第二阶段以真实用户测试集为主，提交地址为：
<https://kaggle.com/competitions/meteorite-identification-stage2>(暂未开放)。
截止时间为6月7日24: 00



- **实验内容：**基于PyTorch深度学习框架，完成陨石识别。
- **潜在方向：**利用上课所学知识提升模型性能（第一阶段应尝试实现70% F1 Score）：
 - 数据：数据增强，数据配比等
 - 模型：修改模型结构等
 - 训练：损失函数，正则化等
- **开展方式：**默认4-5人为一组。如需组成4人以下小组，则算力需自行解决，如使用AutoDL，恒源云等平台。
- **最终目标：**完成最终报告，不多于5页。分析并总结如何利用深度学习技术提升模型分类性能。其他信息例如评分标准，提交要求等将稍后公布。